



정성연

AI, Backend Developer

Python / FastAPI / Docker 기반 AI와 백엔드 개발 및 서버 인프라 구축 경험

[GitHub](#)[Blog](#)[Email](#)

Introduce

AI 기반 웹·앱 프로젝트를 수행하며 백엔드 개발과 인프라 구축을 담당했습니다.

Python/FastAPI 기반 서버 개발, Docker 기반 배포 환경 구성, 데이터 처리 및 서비스 운영 구조 설계 경험이 있으며, 프로젝트 내 PM 역할을 수행하며 일정 관리와 협업 조율도 함께 진행했습니다. 특히 AI 서비스에서는 단순히 모델 성능뿐 아니라, 안정적인 운영과 일관된 품질을 지속적으로 제공하는 구조가 중요하다고 생각합니다. 이를 위해 서비스 구조 설계, 예외 처리, 배포 환경 구성, 유지보수성 등을 고려한 개발을 지향하고 있습니다. 기술적 문제 해결과 서비스 안정성 개선에 관심이 많으며, 실제 사용자 환경에서 신뢰할 수 있는 AI 서비스를 만드는 개발자를 목표로 하고 있습니다.

Skills

AI

PyTorch

Ollama

LangGraph

Backend

FastAPI

Spring Boot

DataBase

MySQL

MongoDB

Neo4J

Qdrant

Infra

Docker

Linux

Nginx

GCP

Frontend

JavaScript(Basic)

Experience

AI Engineer

2025.07 - Present

아파트너스

공동주택관리 AI 플랫폼 아파트케어(구 아지트) 7 개발 및 운영을 담당하며, AI 비서·멀티모달 채팅·문서 자동화 기능 등 LLM 기반 핵심 서비스를 설계하고 구현했습니다. 단순 기능 구현을 넘어, 서비스 확장성과 운영 안정성, 그리고 일관된 AI 품질을 유지할 수 있는 구조 설계에 집중했습니다.

- 공동주택관리 AI 비서 시스템
- 공고문 자동 작성 시스템
- 멀티모달 채팅 시스템
- LLM 모니터링 및 평가 시스템
- 사내 Python 보일러플레이트 구축
- AI 코드리뷰 도입

AI Researcher

2023.03 - 2025.02

인하대학교 HCI 연구실

시계열 분석, 이상 탐지, Computer Vision 기반 산업 AI 연구 및 프로젝트 수행. 논문 연구와 함께 실제 산업 데이터를 활용한 모델 설계 및 실험 파이프라인 구축을 진행했습니다.

- 대기질 이상 탐지 및 xAI 시스템
- AI 기반 타이어 마모 분석 시스템
- 회전설비 이상 진단 및 Remaining Useful Life 예측
- 시계열 및 영상 데이터 기반 산업 AI 연구

Projects

공동주택관리 AI 비서 시스템

2025.07 - Present

아파트너스 · AI Platform

공동주택관리 도메인에 특화된 Agent 기반 AI 비서 시스템 설계 및 개발. 단순 질의응답이 아닌 문서 검색, Tool Selection, 컨텍스트 기반 응답 생성 등을 수행할 수 있는 확장형 RAG 구조를 구축했습니다.

- Agent 기반 Tool Selection 및 동적 Query Pipeline 설계
- Qdrant 기반 Hybrid Search 및 도메인 특화 RAG 구조 구현
- 응답 병목 분석 및 비동기 구조 개선을 통해 평균 응답 속도 15초 → 3초 수준으로 최적화
- Langfuse 기반 LLM 모니터링 및 Prompt 추적 시스템 구축
- 사내 LLM 정량 평가 시스템 구축 및 품질 관리 체계 정립
- RAG 방식 최적화를 통한 토큰 사용량 30% 감소 및 운영 비용 절감
- 2026년 4월 기준 활성 사용자 4,682명, 재방문 비율 81.4%, 일 평균 채팅 2,100건 운영

Python

FastAPI

LLM

RAG

LangGraph

Docker

Qdrant

멀티모달 채팅 시스템

2025.12 - 2026.03

아파트너스 · AI Platform

이미지 및 문서를 함께 처리할 수 있는 멀티모달 기반 AI 채팅 시스템 개발. 실제 서비스 환경에서 안정적으로 동작할 수 있도록 파일 처리 및 응답 파이프라인을 구성했습니다.

- 이미지·문서 업로드 기반 멀티모달 입력 처리 구조 구현
- OCR 및 문서 분석 기반 컨텍스트 추출 시스템 개발
- LLM Context Window 제약을 고려한 대규모 파일 처리 최적화
- 비동기 전송 지원을 위한 이벤트 기반 API 설계
- 운영 안정성을 고려한 파일 처리 예외 및 캐시 구조 개선

Python

FastAPI

LLM

Multimodal AI

공고문 자동 작성 시스템

2025.09 - 2025.010

아파트너스 · AI Automation

공동주택관리 공고문 작성 업무를 자동화하기 위한 LLM 기반 문서 생성 시스템 개발. 사용자 입력과 내부 문서 체계를 기반으로 공고 유형별 템플릿 생성 및 자동화를 구현했습니다.

- 공고 유형별 Prompt 및 Template Pipeline 설계
- 문서 컨텍스트 기반 자동 입력 및 생성 구조 구현
- 반복 행정 업무 감소를 위한 자동화 프로세스 구축
- 서비스 운영 환경을 고려한 예외 처리 및 품질 안정화 수행

Python

LLM

FastAPI

Prompt Engineering

대기질 이상 탐지 및 xAI 시스템

2024.01 - 2024.07

AI Research & Development

시계열 분석과 RAG 기반 xAI를 활용한 대기질 이상 탐지 및 자연어 설명 시스템 개발. 시계열 임베딩 기반 유사 데이터 검색과 LLM 기반 자연어 해석 시스템을 결합했습니다.

- 시계열 임베딩 기반 Vector Search 시스템 구현
- LLM 숫자 비교 문제를 Rule-based 방식으로 개선
- 동적 Query Pipeline 및 Prompt Engineering 설계
- 기존 방식 대비 오탐지율 약 52% 감소

Python

LLM

RAG

ChromaDB

PyTorch

AI 기반 타이어 마모 분석 시스템

2023.02 - 2023.04

AI Research & Development

사용자가 촬영한 타이어 이미지를 기반으로 마모 상태를 추정하는 AI 시스템 개발. Segmentation과 DETR 기반 구조를 활용하여 추론 정확도를 개선했습니다.

- CNN 기반 모델의 배경 과적합 문제 분석 및 개선
- Segmentation 기반 Attention 유도 구조 설계
- DETR 기반 객체 탐지 모델 도입으로 약 20% 정확도 향상 및 오분류율 감소
- 모델 경량화를 위한 Tensor 구조 수정 및 레이어 재구성

PyTorch

DETR

Computer Vision

Transformer

Additional Projects

LLM 기반 영화 큐레이션 서비스

2025.04 - 2025.05

LangGraph 및 Neo4j 기반 자연어 추천 시스템 구현

WebRTC 기반 산업설비 점검 플랫폼

2024.03 - 2024.06

Janus Gateway 및 TURN 서버 기반 화상회의 시스템 구축

회전설비 이상 진단 및 수명 예측 시스템

2023.03 - 2025.02

시계열 진동 데이터 기반 이상 탐지 및 Remaining Useful Life 예측

실시간 이미지 분석 데이터 파이프라인

2023.06 - 2023.09

Apache Storm 기반 실시간 데이터 처리 및 IPC 성능 최적화

Open Source

qdrant-odm ↗

Qdrant 기반 벡터 검색 시스템을 보다 구조적으로 개발할 수 있도록 만든 Python ODM(Object Document Mapper) 라이브러리입니다. 반복적인 컬렉션 및 인덱스 설정, Raw Filter 작성, 스키마 관리 등의 보일러플레이트를 줄이고, Pydantic 기반 모델과 Python DSL을 통해 유지보수 가능한 벡터 검색 구조를 제공합니다.

- Pydantic 기반 Declarative Schema 설계
- Python Expression 기반 Query DSL 구현
- Async Repository 패턴 및 Transaction 지원
- Dense / Sparse / Hybrid Search 지원
- Schema Diff / Dry Run / Sync 시스템 구현
- Multi-tenant Collection 구조 지원

Python

Qdrant

Pydantic

AsyncIO

Others

Papers

국제 저널

A Robust Multivariate Time Series Classification Approach Based on Topological Data Analysis for Channel Fault Tolerance ↗

Sensors (MDPI), 2025

BiVi-GAN: Bivariate Vibration GAN ↗

Sensors (MDPI), 2024

국내 학술대회

위상수학적 데이터 분석을 활용한 Point Cloud Data 분석 방법 연구 ↗

뉴럴 프로세스를 활용한 도로 표지판 이미지 복원 기법 연구 ↗

연속 이미지 분석을 통한 상황 인지 인공지능 모델 연구: 교통사고 과실 산정에 적용 ↗

Certificate

AWS Certified Cloud Practitioner	2024.07
SQLD	2024.09